

Análisis del desempeño de Random Forest con scikit-learn

Nombre: Iris Giselle Balderas Arreola

Matrícula: A01752895

Concentración: Inteligencia Artificial Avanzada para la Ciencia de Datos

Fecha: 16 de septiembre de 2026

Repositorio: https://github.com/Iris-Giselle-Balderas-Arreola/Random_Forest_Analysis

Objetivo

El objetivo de este proyecto fue analizar el desempeño del modelo Random Forest desarrollado con scikit-learn. Para esta entrega se separaron los datos en entrenamiento, validación y prueba, y se comparó el comportamiento del modelo antes y después de ajustar sus parámetros.

Dataset utilizado

Se utilizó el dataset Breast Cancer Wisconsin (Diagnostic), disponible en Kaggle. Cada fila representa una muestra obtenida de una masa mamaria. La variable de salida es diagnosis, donde B significa benigno y M significa maligno.

El archivo contiene 569 registros y 30 variables numéricas. La columna id se conservó para identificar los registros, pero no se utilizó como variable del modelo. La separación se realizó de forma estratificada con una semilla de 42.

Conjunto	Total	Benignos	Malignos
Dataset completo	569	357	212
Train	341	214	127
Validation	114	71	43
Test	114	72	42

Fuente del dataset: Breast Cancer Wisconsin Data - Kaggle

Evaluación

Para este análisis se seleccionó la implementación de Random Forest desarrollada con librerías, utilizando `scikit-learn`. Esta versión fue elegida debido a que permite evaluar de manera más directa el desempeño del modelo mediante conjuntos de entrenamiento, validación y prueba, además de facilitar el ajuste de hiperparámetros. A partir de esta implementación se analizaron el bias, la varianza y el nivel de ajuste del modelo, comparando posteriormente el desempeño del modelo base contra una versión ajustada. La implementación manual sin librerías no fue utilizada para esta etapa del análisis.

Modelo base

El modelo base conserva la configuración utilizada en la entrega anterior. Se construyeron 100 árboles con una profundidad máxima de 8 y una muestra mínima por hoja de 1.

Parámetro	Valor	Uso
n_estimators	100	Cantidad de árboles
max_depth	8	Profundidad máxima
min_samples_split	2	Mínimo para dividir un nodo
min_samples_leaf	1	Mínimo de registros por hoja
max_features	sqrt	Variables revisadas por división
bootstrap	True	Muestreo con reemplazo
random_state	42	Permite repetir el resultado

Resultados del modelo base

Conjunto	Exactitud	Precisión	Sensibilidad	Especificidad	F1
Train	100.00%	100.00%	100.00%	100.00%	100.00%
Validation	97.37%	97.62%	95.35%	98.59%	96.47%
Test	95.61%	97.44%	90.48%	98.61%	93.83%

El modelo alcanzó 100% de exactitud en Train, 97.37% en Validation y 95.61% en Test. La diferencia entre el resultado de entrenamiento y el conjunto de prueba fue de 4.39 puntos porcentuales.

Diagnóstico de bias, varianza y ajuste

Bias

El bias se consideró bajo. El modelo obtuvo 100% de exactitud en Train, por lo que tiene capacidad suficiente para representar los patrones del conjunto de entrenamiento.

Varianza

La varianza se consideró media. Aunque Validation se mantuvo en 97.37%, el resultado bajó a 95.61% en Test. La diferencia máxima respecto a Train fue de 4.39 puntos porcentuales.

Nivel de ajuste

El modelo base presenta overfit leve. La curva de aprendizaje muestra que la exactitud de Train permanece en 100% incluso cuando cambia la cantidad de datos, mientras Validation se mantiene por debajo.




Figura 1. Curva de aprendizaje del modelo base.

La separación entre ambas líneas no es grande, pero es constante. Esto respalda el diagnóstico de bias bajo con una varianza que todavía puede reducirse.

Ajuste de parámetros

Para reducir el sobreajuste se compararon distintas profundidades máximas y cantidades mínimas de registros por hoja. La selección se realizó con Train y Validation. Test no se utilizó para escoger la configuración.

Profundidad	Mínimo por hoja	Train	Validation	F1 Validation	Diferencia
6	4	98.83%	97.37%	96.47%	1.46%
8	4	98.83%	97.37%	96.47%	1.46%
4	4	99.12%	97.37%	96.47%	1.75%
5	4	99.12%	97.37%	96.47%	1.75%
4	1	99.41%	97.37%	96.47%	2.05%

Las configuraciones principales obtuvieron el mismo resultado en Validation. Se seleccionó profundidad 6 y mínimo de 4 registros por hoja porque mantuvo el desempeño de validación y redujo la diferencia con Train. Ambos cambios limitan la complejidad de los árboles.




Figura 2. Exactitud antes y después del ajuste.

Después del ajuste, Train bajó de 100% a 98.83%, Validation se mantuvo en 97.37% y Test aumentó de 95.61% a 96.49%.

Modelo ajustado

El modelo ajustado utiliza 100 árboles, profundidad máxima de 6 y un mínimo de 4 registros por hoja. Los demás parámetros se conservaron iguales al modelo base.

Conjunto	Exactitud	Precisión	Sensibilidad	Especificidad	F1
Train	98.83%	98.43%	98.43%	99.07%	98.43%
Validation	97.37%	97.62%	95.35%	98.59%	96.47%
Test	96.49%	100.00%	90.48%	100.00%	95.00%

El bias se mantiene bajo porque la exactitud de Train es 98.83%. La varianza se considera baja porque la diferencia máxima entre Train y los otros conjuntos disminuyó a 2.34 puntos porcentuales. Por esta razón el modelo ajustado se considera fit.




Figura 3. Curva de aprendizaje del modelo ajustado.

Con más datos de entrenamiento las curvas quedan más cercanas. A diferencia del modelo base, Train ya no permanece en 100%, lo que indica que se redujo el sobreajuste.

Resultados en el conjunto de prueba




Figura 4. Modelo base.




Figura 5. Modelo ajustado.

El modelo base obtuvo 71 verdaderos negativos, 1 falso positivo, 4 falsos negativos y 38 verdaderos positivos. El modelo ajustado corrigió el falso positivo y mantuvo los otros resultados, por lo que terminó con 72 verdaderos negativos, 0 falsos positivos, 4 falsos negativos y 38 verdaderos positivos.

Modelo	VN	FP	FN	VP	Exactitud Test	F1 Test
Base	71	1	4	38	95.61%	93.83%
Ajustado	72	0	4	38	96.49%	95.00%

La sensibilidad permaneció en 90.48%, por lo que los cuatro falsos negativos siguen siendo el punto principal a considerar. La mejora observada provino de eliminar el falso positivo y de reducir la diferencia entre entrenamiento y prueba.

Análisis

El modelo base tenía un desempeño alto, pero la exactitud perfecta en entrenamiento y la reducción observada en Test mostraban un sobreajuste leve. El problema no era un bias alto, sino que el modelo estaba aprendiendo con más detalle el conjunto de entrenamiento de lo necesario.

El ajuste de `max_depth` y `min_samples_leaf` permitió reducir la complejidad de los árboles. Validation no perdió desempeño y la diferencia máxima entre conjuntos bajó de 4.39 a 2.34 puntos porcentuales. En Test la exactitud aumentó de 95.61% a 96.49% y el F1 de 93.83% a 95.00%.

Los cuatro falsos negativos permanecieron después del ajuste. Debido a que representan casos malignos clasificados como benignos, una mejora posterior podría revisar pesos de clase o el umbral de decisión, pero esos cambios no se utilizaron en esta entrega.

Conclusión

La separación Train / Validation / Test permitió revisar el comportamiento del modelo de forma más completa. El Random Forest base presentó bias bajo, varianza media y overfit leve. Después del ajuste, el modelo mantuvo bias bajo, redujo la varianza y quedó clasificado como fit.

La configuración final utiliza 100 árboles, profundidad máxima de 6 y un mínimo de 4 registros por hoja. El resultado final en Test fue 96.49% de exactitud y 95.00% de F1.

Pruebas del código

El proyecto incluye cuatro pruebas automáticas para revisar la configuración del modelo, la separación Train / Validation / Test, el entrenamiento y el cálculo de métricas. Las pruebas terminaron correctamente.

Enlaces

Repositorio del proyecto: [Random_Forest_Analisis](#)

Dataset: Breast Cancer Wisconsin Data